Relatório de qualidade dos dados - Entrega 5

Disciplina: TPAE II (PSAE00320) | **Turma:** 012026.2

Equipe 03: Thiago Fernandes Ferreira de Oliveira, Matheus Lima Fonseca, Matheus Guilherme da Silva Lima

Projeto: Planejamento de Exportação para PMEs na Paraíba (Corecon-PB)

Repositório GitHub: https://github.com/thiagopapel-econ/projeto-tpae-II

Processado em: 06/11/2026 | **Notebook Colab:** Acessar Notebook (`codigo/E05_tratamento_dados.ipynb`)

1. Fontes (originais preservados em dados/brutos/)

base	arquivo	extração	ano inicial	ano final	linhas lidas	dimensões da consulta (Detalhamento)
1	H_EXPORTACAO_POR_MUNICIPIO_2021-01_2025-12_DT20261022.xlsx	2026-10-22	2021	2025	436	UF do Município | Município | Posição (SH4)
2	H_EXPORTACAO_POR_MUNICIPIO_2026-01_2026-12_DT20261022.xlsx	2026-10-22	2026	2026	154	UF do Município | Município | País

2. Produtos gerados (dados/tratados/)

arquivo	linhas	grão
exportacoes_municipio_produto_2021_2025.csv	829	municipio x SH4 x ano
exportacoes_municipio_pais_2026.csv	154	municipio x pais (2026, possivelmente parcial)
exportacoes_municipio_consolidado.csv	48	municipio
exportacoes_municipio_ano.csv	180	municipio x ano

3. Problemas encontrados, decisões aplicadas e impacto/validação

Variável/base	Problema encontrado	Decisão aplicada	Impacto/validação
Código SH4 (base 1)	Tipo misto na planilha (412 células inteiras e 24 de texto). A leitura automática do pandas converte tudo para inteiro e remove o zero à esquerda (24 códigos afetados, ex.: '0807' viraria 807).	Leitura como texto (dtype=str) e padronização em 4 digitos; criado capitulo_sh2; sh4 exportado como texto (README e dicionário orientam a leitura com dtype=str).	0 códigos inválidos; 259 SH4 distintos; 0 códigos com descrição conflitante; chave (município, SH4) sem duplicatas.

Variável/base	Problema encontrado	Decisão aplicada	Impacto/validação
Descrição SH4 (base 1)	78 linhas (49 códigos SH4) com espaço não separável (U+00A0, ex.: 'posição 0105') nas descrições. Cada código tem uma única descrição.	Espaços normalizados para espaço simples em descricao_sh4; conteúdo textual mantido como na fonte (os originais permanecem intactos).	0 códigos com descrições conflitantes; a chave (SH4) não é afetada.
Município (bases 1 e 2)	Nome e UF juntos na mesma coluna ('Campina Grande - PB'); planilhas sem código IBGE do município.	Separação em municipio_nome e uf_sigla; criação de municipio_chave (sem acento, minúsculo, espaços normalizados + UF) como identificador comum. Nenhum código foi inventado.	0 nomes fora do padrão; 0 UF incoerentes; 0 nomes com espaços anômalos; 0 colisões de chave: 0 grafias suspeitas entre as bases.
Valores ausentes (ambas)	Nenhuma célula ausente na aba Resultado (nulos: base 1=0; base 2=0).	Nada a imputar. Ausências que surgem na consolidação (município sem registro em um periodo) permanecem vazias, nunca preenchidas com 0.	Teste: nulos remanescentes limitados a preço indefinido (kg=0) e municipios sem registro no periodo; todos explicados.
Duplicidades (ambas)	Linhas totalmente duplicadas: base 1=0, base 2=0. Chaves repetidas (municipio+SH4/municipio+pais): 0/0; após a padronização: 0/0.	Nenhuma exclusão necessária.	Teste de unicidade das chaves naturais aprovado em todas as tabelas.
Valor FOB e Quilograma Liquido (tipos)	Valores numéricos lidos como texto (dtype=str) para evitar coerção silenciosa. Falhas de conversão: 0; negativos: 0.	Conversão para int64 (valores inteiros em US$ e kg); nenhum valor alterado.	Totais por ano idênticos aos dos originais (teste 6.3).
Zeros no formato largo (base 1)	1.351 de 2.180 células município x produto x ano têm FOB=0 e kg=0: no Comex Stat significam ausência de registro naquele ano, não 'exportação zero' nem dado faltante.	Não imputados. Omitidos ao passar para o formato longo (uma observação por linha); permanecem nos dados originais.	Formato longo: 829 observações (= células com registro). Soma das células omitidas = 0 totais anuais de FOB e kg idênticos ao original.
Linha totalmente zerada (base 1)	1 linha(s) municipio x produto sem valor em nenhum ano: João Pessoa - PB/SH4 4822.	Mantida em limpo_A (e nos originais); sem observações no formato longo por não ter registro.	Nenhum valor de exportação perdido; o município segue presente por outros produtos.

Variável/base	Problema encontrado	Decisão aplicada	Impacto/validação
FOB > 0 com kg=0	Valor positivo com peso zero: base 1=52 observações; base 2=3.0 preço por kg é indefinido (pode refletir peso arredondado para zero ou mercadoria sem peso relevante).	Valores originais mantidos. preco_medio_usd_kg = vazio (NaN), nunca 0 nem infinito.	Teste: preço vazio exatamente onde kg=0 (52 obs. na base 1; 3 na base 2).
FOB=0 com kg > 0	Peso positivo com valor zero: base 1=1 observação(ões); base 2=0.	Mantido como na fonte (preço = 0). Participações tratam o valor 0 normalmente.	Não afeta totais de FOB; apenas peso.
Preço médio por kg (valores extremos)	Preços implicitos de US$ 0,0021 a US$ 10.593 por kg (base 1) e até US$ 203.333/kg na base 2. Os extremos vêm de pesos pequenos (1 a 3 kg) ou de mercadorias de valor unitário diferente; produtos distintos não são comparáveis em US$/kg.	Valores extremos diagnosticados e mantidos (sem winsorização ou exclusão, pois não há critério objetivo de erro). Preço de agregados = razão dos totais. Comparar preços apenas dentro do mesmo SH4.	Tabelas de maiores/menores preços na Etapa 5.5; totais de FOB e kg não são afetados.
Granularidade diferente e chaves sem correspondência (bases)	Base 1 = município x produto; base 2 = município x pais. 48 municípios na base 1; 25 na base 2. Um merge direto geraria 7.009 linhas e inflaria o FOB de 2025. Período 2026 (base 2) não representa o ano completo.	Junção direta rejeitada. Três tabelas + dim_municipio. A consolidada resulta de agregar cada base ao município antes de juntar. Todos os municípios mantidos (outer join); período 2026 marcado como parcial.	Totais antes e depois conferem; nenhuma tabela contém produto e pais juntos; chaves únicas. Nenhum município descartado. Limitação permanece para comparações de 2026.
UF e filtros (Detalhamento)	A aba Detalhamento mostra consulta 'Por Municipio', fluxo Exportação, filtro UF=25 (Paraíba).	Parâmetros lidos e registrados em registro_fontes.csv (inclui SHA-256, data da extração e versão do pandas).	Testes: linhas declaradas = linhas lidas; anos conferem; todas as linhas com UF=PB.
País de destino (base 2)	Países sem código padronizado (ex.: 'Países Baixos (Holanda)', 'Taiwan (Formosa)'). Países distintos: 64; grafias conflitantes: 0.	Grafias mantidas como na fonte; apenas espaços normalizados.	Soma dos países = FOB total de 2026 (teste).

Variável/base	Problema encontrado	Decisão aplicada	Impacto/validação
Unidades e valores monetários	Valores em US$ FOB correntes (nominais, sem deflator) e peso em quilograma líquido; as planilhas não informam outra unidade.	Sem conversão de unidade. Nomes das colunas explicitam a unidade (valor_fob_usd, kg_liquido).	Limitação: comparações entre anos refletem valores nominais, não poder de compra.
Limitações que permanecem	Sem informação de empresa, porte (PME) ou CNPJ; sem relação produto x país; atribuição ao municipio segue a metodologia do Comex Stat; sem código IBGE.	Documentadas. Próximas entregas poderão ligar a chave municipal ao código IBGE (DTB) e às bases RAIS/CNPJ.	57/57 testes de integridade aprovados.

4. Validação: 57 de 57 testes de integridade aprovados

grupo	testes	aprovados
6.1 Detalhamento	7	7
6.1 Preservação	2	2
6.2 Contagens	7	7
6.3 Totais	11	11
6.4 Chaves	8	8
6.5 Consistência	1	1
6.5 Participações	6	6
6.5 Valores	7	7
7.1 Dicionário	4	4
7.2 Exportação	4	4

Totais de referência (US$ FOB nominais): 2021-2025 = US$ 1.021.021.321; 2026 = US$ 88.177.849 (período possivelmente parcial, extração em 22/10/2026; não comparável diretamente a anos completos).